



 最新更新: [hGps://dl.acm.org/doi/10.1145/3544216.3544265](https://dl.acm.org/doi/10.1145/3544216.3544265)

研究论文

木星进化：通过光电路交换机和软件定义网络改造谷歌数据中心网络

LEON POUTIEVSKI, 谷歌有限责任公司, 美国加利福尼亚州山景城OMID

MASHAYEKHI, 谷歌有限责任公司, 美国加利福尼亚州山景城JOON ONG, 谷歌有
限公司, 美国加利福尼亚州山景城

阿琼·辛格, 谷歌有限责任公司, 美国加利福尼亚州山景城穆卡拉姆·本·塔里克, 谷歌有
限公司, 美国加利福尼亚州山景城王瑞, 谷歌有限责任公司, 美国加利福尼亚州山
景城

[查看全部](#)

开放获取支持由:

[谷歌有限责任公司](#)



PDF下载
3544216.3544265.pdf
2026年1月14日
总引用次数: 175
总下载量: 16587

发表日期: 2022年8月22日

[BibTeX格式引用格式](#)

SIGCOMM '22: ACM SIGCOMM 2022
会议

2022年8月22日至26日 荷
兰阿姆斯特丹

会议赞助商:
SIGCOMM

木星进化：通过光电路交换机与软件定义网络改造谷歌数据中心网络

软件定义网络实现转型

列昂·普蒂耶夫斯基、奥米德·马沙耶基、翁俊、阿琼·辛格、穆卡拉姆·塔里克、王瑞、
张建安、弗吉尼亚·博雷加德、帕特里克·康纳、史蒂夫·格里布尔、里希·卡普尔、
斯蒂芬·克拉泽、李南方、刘红、卡蒂克·纳加拉吉、
杰森·奥恩斯坦、萨米尔·索尼、浦田亮平、洛伦佐·维奇萨诺、凯文·安村、张世东、周俊兰、阿
明·瓦赫达特
谷歌
sigcomm-jupiter-evolving@google.com

摘要

我们展示了Jupiter数据中心网络架构十年的演进与生产实践。在此期间，Jupiter实现了5倍的速度与容量提升，资本支出降低30%，能耗减少41%，同时支持渐进式部署与技术更新，全程保障生产流量正常运行。这些改进的关键驱动力在于将Jupiter从闭环拓扑(Clos)演进为机器聚合块间的直连拓扑。关键架构变革包括：采用基于微机电系统(MEMS)的光学电路交换机(OCS)构建数据中心互连层，实现动态拓扑重构；通过集中式软件定义网络(SDN)控制实现流量工程化；以及自动化网络运维以支持增量容量交付与拓扑工程。我们证明，在直接连接结构上结合流量和拓扑工程，对于我们的生产流量模式，可实现与克洛斯结构相似的前置量。我们还优化了路径长度：60%的流量从源到目标聚合块采用直接路径，其余流量仅额外经过一个块，使我们当前机群的平均块级路径长度达到1.4。与采用配线架互连的传统Clos结构相比，OCS实现了3倍更快的结构重构速度。

CCS 概念

• 网络 → 数据中心网络；流量工程算法；网络可管理性；



本作品采用知识共享署名 4.0 国际许可协议进行许可

SIGCOMM'22, 2022年8月22-26日, 荷兰阿姆斯特丹

© 2022 版权所有/作者所有。ACM ISBN 978-1-

4503-9420-8/22/08。

<https://doi.org/10.1145/3544216.3544265>

关键词

数据中心网络、软件定义网络、流量工程、拓扑工程、光电路交换机。

ACM参考文献格式：

列昂·普蒂耶夫斯基、奥米德·马沙耶基、翁俊、阿琼·辛格、穆卡拉姆·塔里克、王瑞、张建安、弗吉尼亚·博雷加德、帕特里克·康纳、史蒂夫·格里布尔、里希·卡普尔、斯蒂芬·克拉泽、李南方、刘红、卡蒂克·纳加拉吉、杰森·奥恩斯坦、萨米尔·索尼、浦田亮平、洛伦佐·维奇萨诺、凯文·安村、张世东、周俊兰、阿明·瓦赫达特 Google sigcomm-jupiter-evolving@google.com
. 2022. 木星进化：通过光环路交换机和软件定义网络改造谷歌数据中心网络. 收录于ACM会议论文集 (SIGCOMM'22). ACM出版社, 美国纽约州纽约市, 20页. <https://doi.org/10.1145/3544216.3544265>

1 引言

基于商用硅芯片构建的软件定义网络与闭环拓扑结构[1, 2, 14, 24, 33], 已实现成本效益高且可靠的建筑级数据中心网络, 成为云基础设施的基础。各类网络服务、机器学习工作负载及存储基础设施, 通过数万台服务器间统一的高带宽连接, 发挥出卓越效能。

尽管取得了巨大进展, 但管理建筑级网络的异构性和渐进式演进却相对缺乏关注。云基础设施的扩展往往是渐进式的, 通常一次仅增加一个机架甚至一台服务器。因此, 填满一座初始空置的建筑可能需要数月乃至数年时间。当初始容量饱和后, 基础设施仍以增量方式演进——通常每次仅升级一个机架至最新一代服务器硬件。网络生命周期内, 服务器类型、存储设备、加速器或服务项目的增减往往缺乏预先规划。指数级增长的现实与不断变化的业务需求, 使精心制定的计划迅速过时失效, 这

使得增量式与自适应演进成为必然选择。

计算和存储基础设施的增量更新相对简单：只需在数据中心数百或数千个机架中抽调一个机架的容量，用新一代硬件替换即可。而网络基础设施的增量更新则更具挑战性，因为Clos结构要求至少预先构建整个网络的脊柱层。遗憾的是，这种做法将数据中心的可用带宽限制在脊柱部署时所采用的网络技术速度上。

考虑一个典型的三层Clos网络，由配备机架顶部交换机（ToR）的机器机架、连接机架的汇聚模块以及连接汇聚模块的脊柱模块构成（图1）。传统Clos方案需要采用当时的技术预先构建最大规模的脊柱网络（例如使用Jupiter[33]实现64个汇聚模块）。采用40Gbps技术时，每台脊柱交换机可支持20Tbps突发带宽。当新一代100Gbps技术投入使用后，新型汇聚模块虽能支持51.2Tbps突发带宽，但受限于既有脊柱模块40Gbps的链路速率，导致每个汇聚模块的实际容量降至20Tbps。最终，由于数据中心网络带宽不足，单台服务器和存储设备的容量将被迫降级。在计算能力提升而网络带宽未同步增长的情况下，系统将陷入失衡状态，导致昂贵的服务器资源闲置。遗憾的是，Clos拓扑的固有特性决定了：仅对主干进行增量升级，只能使新一代汇聚模块获得有限的容量提升。全面更新整栋建筑规模的骨干网络同样不可取——这不仅成本高昂、耗时费力，更因需重构整个网络结构而导致运营中断。

我们提出一种全新的端到端设计，通过引入光电路交换机（OCS）[31]¹，将Jupiter网络拓扑从Clos结构转变为块级直接连接拓扑。这种转变彻底消除了脊柱交换层及其相关挑战，使Jupiter能够逐步集成40Gbps、100Gbps、200Gbps及更高网络速率。该直连架构结合网络管理、流量与拓扑工程技术，使Jupiter能够应对流量不确定性、显著的结构异构性，并在无需停机或服务中断的情况下实现演进。相较于静态Clos结构，这些变革不仅带来5倍的速度与容量提升及额外灵活性，更实现了架构层面的30%成本削减与41%功耗降低。

本工作未引发任何伦理问题。

2 木星架构的演进策略

本节概述了Jupiter架构为解决§1所述问题所进行的演进。

¹ 附录（§F, [41]）详细阐述了Jupiter项目中采用的OCS平台硬件设计及WDM收发器技术。




图1：三层Clos网络由机器机架、聚合模块及连接聚合模块的40Gbps脊骨模块构成。所有脊骨模块均在第1天部署第2天部署的模块以蓝色轮廓标注，第N天部署的模块则以红色高亮显示。由于40Gbps脊骨模块的限制，来自100Gbps汇聚模块的链路速率需降额至40Gbps。




图2：光交换层DCNI（顶部）使Jupiter能够实现增量扩展，同时在聚合模块间实现全突发带宽（底部逻辑拓扑）。DCNI层采用光环路开关（OCS）实现，可在新增模块时对网络结构进行增量重连。详见第5节。




图3：采用环形器实现收发双工，并通过OCS实现不同代粗波分复用（cWDM）光模块的互操作。

数据中心互连层。 Jupiter fabric[33]采用商用硅芯片作为聚合与骨干模块的基础，进而构建出适用于楼宇级数据中心的Clos结构。我们引入光交换数据中心网络互连层（DCNI）连接各模块。该层采用基于MEMS的光电路交换机（OCS），实现模块间链路的快速、可靠且高效重分条（图2）。通过重分条技术，可在逐步增加汇聚模块的同时，维持所有汇聚模块间的全突发带宽。




图4：历代交换机与光模块功耗随带宽递减趋势（功耗/带宽比，pJ/b，以40Gbps代为准）。

和主干模块，消除了图1所示的前置部署主干模块的难题。如后文所述，光开关还支持软件驱动流量感知拓扑重构（拓扑工程）。第3.1节将详细阐述DCNI层架构。

多代互操作性。聚合和骨干模块是部署单元，通常采用当时最具成本和性能竞争力的网络技术。然而，由于数据中心的寿命远超单一技术的竞争周期，在单一网络结构中部署多代技术不可避免。为此，Jupiter必须支持模块化块中多代交换芯片和链路速率的共存与互操作。在汇聚模块接口采用粗波分复用4通道（CWDM4）光模块，是实现异构网络中跨链路世代互操作简化的关键（图3）。得益于这种互操作性，Jupiter能够逐步演进并支持异构化常态化：舰队中约三分之二的网络架构拥有至少两代汇聚模块。

优化光交换成本。我们采用多项技术精简光交换层成本：

- **利用环形器将所需光交叉端口减半。**我们采用光环形器（图3，§F.3）将发射端与接收端双工化至单根光纤即可实现，所需OCS端口和光纤数量减半。这引入了一个轻微限制：需要双向电路而非单向电路——鉴于我们数据中心观察到的流量模式，这是我们在成本与灵活性之间做出的权衡选择。
- **增量基数升级。**聚合区块的总流量取决于以下因素：应用程序的网络带宽密集度以及区块内流量的局部性程度。通常情况下，区块间流量需求远低于聚合区块的最大区块间容量。Jupiter初期部署时，多数区块仅启用面向DCNI的光模块半数容量。

端口并支持后续在运行中的网络结构上升级基数，将光模块和对应的OCS端口成本推迟至实际需要时才产生（§3.1, [33]）。

- **DCNI的增量部署。**随着更多汇聚和脊骨模块加入网络时，所需DCNI端口数量将逐步增加。因此Jupiter并未预先部署最大规模的DCNI，而是通过在运行中的网络上分三阶段部署和扩展DCNI层来延迟OCS成本：
1/8→1/4→1/2→全尺寸。

§5 描述了在运行中的结构上实现这些增量部署变更和无损重配置的过程。**直接连接架构。**图1表明，随着更高链路速度的新技术引入，链路速度降额使主干节点成为主要瓶颈。虽然它通过逐步更新主干模块或其线路卡[2]，可缓解部分问题，但此类方法会增加成本、引发全网络范围的操作负担及生产风险。我们的多租户和建筑级网络具有相对可预测的流量模式，其不确定性远低于最坏情况排列（§6.1），因此无需Clos拓扑[10]支持的最坏情况排列流量非阻塞转发。基于上述观察，*我们通过流量与拓扑工程（§4）优化了块间转发与拓扑结构，在实现短效路径的同时兼顾流量预估不确定性，从而在拓扑中移除了脊柱块，构建了直连式结构（§3）。*

直接连接技术还消除了与骨干网块相关的成本和功耗（§6.5）。这种结构性运营成本的降低尤为重要，因为随着交换机和光模块速度的每一代迭代升级，硬件性能提升的边际效益递减，且标准化功耗成本也呈递减趋势（图4）。

3 直接连接木星

木星的新架构通过DCNI层直接连接聚合块。图5展示了此类结构中增量部署、流量与拓扑工程的实际应用。初始结构仅需两个块即可构建，随后可逐步扩展（图5.01、02）。模块间的直接逻辑链路包含三部分：各模块到光交叉连接器（OCS）的物理链路，以及OCS交叉连接器（图3）。依托OCS，逻辑链路可通过编程方式动态构建（第5节）。

对于同质块，我们将逻辑链路平均分配给所有块对。若需求与逻辑拓扑完全匹配，所有流量均可通过源块与目标块间的直连路径传输。实际中，需求具有波动性且与逻辑拓扑存在偏差。Jupiter系统采用*流量工程技术*（§4.4），通过直连路径与单跳间接路径的组合，在性能与抗流量不确定性鲁棒性之间实现平衡（图5.03）。




图5: 采用动态流量与拓扑工程增强的直接连接拓扑结构, 可增量部署的木星网络架构。①: 初始阶段, 聚合区块A、B各添加512条上行链路。②: 区块C添加512条上行链路。每个区块拥有50T外发需求, 均匀分布至其他区块。拓扑工程构建均匀网格拓扑, 匹配均匀稳态需求矩阵。③: 流量工程 (TE) 根据②中更精细的需求版本调整加权成本多路径 (WCMP) 权重: A将全部流量 (20T) 直接发送至B (粉色路径), 并将发往C的流量 (25T) 按5:1比例 (25T:5T) 分配至直连与间接路径 (经由B)。④: 新增D区块, 配备256条上行链路 (仅部署D区部分机架)。⑤: D区块扩容至512条上行链路。⑥: C、D区块链路速率升级至200G。

我们采用**拓扑工程** (§4.5) 进一步优化拓扑结构以适应需求。在图5④中, 由于A/B/C区块与D区块之间的需求较低, 拓扑工程在A、B、C区块间分配了更多直连链路, 而非连接至D区块的链路。我们还根据非均匀流量需求 (图5⑤) 以及 异构区块的链路速率 (图5⑥) 调整了拓扑结构。

3.1 数据中心互连层

DCNI层的OCS设备部署于专用机架中。机架数量因项目而异, 但需在部署首日根据最大预期网络容量进行规划。最大规模为32个机架, 每个机架最多可容纳8台OCS设备。网络初始可采用每机架部署一台OCS (占用1/8容量), 后续通过在。此类扩展需人工移动光纤, 但我们的光纤设计布局将移动限制在机架内部, 从而减少干扰和人力投入。

我们将每个超级块的链接均匀分发至所有OCS节点。这使我们能够构建任意逻辑拓扑结构[46]。由于采用了环形器, 每个块连接至各OCS节点时端口数必须为偶数。这些约束最终决定了连接模式, 并随着网络规模扩展触发DCNI层的扩展。该设计同时实现了物理多样性, 使得单个OCS机架故障对每个Jupiter模块的影响均等。例如, 在32个OCS机架的部署中, 单个机架故障将使容量均等降低1/32, 且该影响与整体结构规模无关。




图6: 多层逻辑拓扑因子分解示意图。左侧: 自上而下, 我们从块级图开始, 将其分解为4个因子 (每个因子对应25%的故障域, 图中仅示例两个), 最终将每个因子映射至一个OCS (实际存在多个OCS)。a、b...分别表示来自块A、B...的端口。每个模块与每个OCS的端口数均为偶数。图中示例性地将两个端口分别放置在OCS的南北两侧。OCS仅能将北侧端口与南侧端口进行交叉连接。右侧: 当块级图发生变化 (如§4.5所述拓扑工程) 时, 在每个分解层级上, 我们最小化新因子与当前因子的差异。本例中红色因子保持不变, 蓝色因子有两条逻辑链路发生变更。

3.2 逻辑拓扑

初始阶段采用静态且不考虑需求的拓扑结构。对于具有相同模块速度和基数的模块, 我们采用

统一网格用于互连模块；每对模块具有相等数量（相差不超过1）的直接逻辑链路。统一拓扑结构使任意模块对仅通过直接链路及单跳间接路径即可突发至模块的最大输出带宽（§4.3）。对于具有不同基数的同质模块，我们设定模块间链路数量与基数乘积成正比。例如，两个基数为512的模块间链路数量是两个基数为256的模块间链路的4倍。§6.1和§C节提供更多细节。但在常见场景中，网络结构通常包含不同代际和支持速率的聚合模块。此时我们依赖流量感知拓扑工程，根据观测到的需求矩阵优化吞吐量和路径选择（§4.5）。

确定顶级逻辑拓扑后，我们需要将块级图分解为每个OCS的端口级连接关系（图6展示了一个示例）。我们将块的端口划分为四个故障域，每个故障域包含25%的端口（图7）。理想情况下，故障域应具有等效影响，即单个故障域失效后残留拓扑的吞吐量应保留 $\geq 75\%$ 的原始吞吐量。我们通过施加平衡约束来实现这一目标：

故障域后，保留的吞吐量应 $\geq$ 原始拓扑的75%。我们通过施加平衡约束来实现这一目标。

这要求对应于不同故障域的子图大致相同。这样，如果原始拓扑结构不均匀，残余拓扑结构将保持与原始拓扑相同的比例关系。

在重构逻辑拓扑时，我们通过最小化新端口连接与当前端口连接之间的差异，进而实现：i) 需重构的逻辑链路数量最小化，以及 ii) 拓扑变迁期间必须释放的容量最小化（§5）。针对脊柱-全连接拓扑的类似分解问题被证明属于NP难问题[49]。我们采用基于整数规划的多级分解可扩展近似算法[21]。该技术可在数分钟内解决最大网络结构的任意块级拓扑问题，同时将重构链路数控制在最优值的3%以内。

4 流量与拓扑工程

在后续章节中，我们将探讨两个层级的网络适应机制。第一层级——流量工程（TE）——运行于逻辑拓扑之上，基于反映通信模式的实时需求矩阵，优化跨路径的流量转发。该机制必须管理因条带化、故障或管理操作导致的区块间连接失衡问题。第二层级——拓扑工程（ToE）——通过调整拓扑结构本身来提升带宽效率（§4.5）。

实施这些优化时有两个主要目标：吞吐量与效率。首先，需满足动态变化的流量需求矩阵，同时预留足够余量以应对流量突发、网络故障及维护需求。其次，应优先利用直接路径而非间接路径。我们将直接路径数量称为

跨块级边缘的延展度由跨块流量决定。直接块级路径的延展度为1.0。经由脊柱块或另一聚合块的间接路径延展度为2.0（参见附录A示意图）。间接路径消耗更多容量并增加往返时间（RTT），尤其对小流量而言会显著影响流量完成时间（FCT）（参见6.4节）。因此，我们需在优化吞吐量与延展性的同时，兼顾流量不确定性，确保网络在连续优化周期间维持良好性能。本节后续将阐述控制平面组件（特别是OCS控制器），随后分别深入探讨流量工程与拓扑工程的设计方案，最后说明两者的交互机制。

4.1 控制平面设计

猎户座（Orion）作为木星的SDN控制平面[12]，负责编程数据平面交换机以实现所需流量流，包括流量工程相关操作。网络操作层用于拓扑重构，包括拓扑工程（§5）。

Orion通过将路由功能划分为两级实现高可用性（图7）。在第一级，每个聚合块构成独立的Orion域。路由引擎（RE）作为Orion的域内路由应用，在块内提供连接性，并作为与其他域建立外部连接的接口。Orion还对OCS设备进行编程（§4.2）：我们将OCS设备划分为四个独立的Orion域（DCNI域），每个域承载25%的OCS设备，以在OCS控制平面故障时限制影响范围。

控制层级的第二层负责聚合块间的链路连接。我们将这些链路划分为四种互斥颜色，每种颜色由独立的Orion域控制。域间的路由器中心（IBR-C）作为域间路由应用，通过计算域间转发路径并协调

路由广告用于区块间链路。

该设计将单个流量工程域对数据中心网络基础设施(DCNI)的影响限制在25%以内。然而，这种风险降低是以牺牲部分可用带宽优化机会为代价的，因为每个域都基于其对拓扑结构的视图进行优化，尤其涉及计划性事件（如重新分条而清空的容量）或非计划性事件（如设备故障）导致的不平衡情况。

4.2 光引擎控制器

光引擎通过根据网络运维层的交叉连接意图编程OCS，在汇聚模块间建立逻辑连接（图7）。为与数据包交换机保持一致性，我们为OCS实现了OpenFlow[25]接口，其中每个OCS交叉连接被编程为两个流：它们在输入端口匹配，并转发至输出端口：

```
匹配 {IN_PORT 1} 指令 {APPLY: OUT_PORT 2} 匹配 {IN_PORT 2} 指令 {APPLY: OUT_PORT 1}
```





图7: Orion控制与网络管理系统。

光交叉开关（OCS）在静态故障时保持最后编程的交叉连接，类似于分组交换机的行为。这使得即使控制平面断开连接，数据平面仍可保持可用。当控制连接重新建立时，光引擎会与光交叉开关协调流量，然后根据最新意图进行编程。虽然在静态故障期间网络性能可能下降，但这种下降是渐进的。因此，这种性能下降的风险远低于因控制平面断开导致数据平面完全丧失的风险。

OCS在断电时不会维持交叉连接，导致逻辑链路中断。模块间路由可管理小幅度容量突发损失（例如每个模块的OCS机架仅影响32机架部署中总DCNI链路的1/32。然而，若多个OCS设备同时断电将引发严重问题。我们通过将OCS供电域与控制域对齐，确保即使发生重大建筑级供电故障，最多也仅影响25%的OCS设备。尽管极少发生，但更具破坏性的供电事件仍需防范。

OCS设备将引发严重问题。我们通过将OCS供电域与控制域对齐，确保即使发生重大楼宇级供电故障，最多也仅影响25%的OCS设备。虽然极端灾难性供电事件发生概率极低，但若发生，DCNI层将与服务器、存储设备及数据平面交换机共同承受影响。针对此类情况，我们依赖独立负载均衡系统将应用层流量从受影响的结构中转移。

在光引擎之外，Orion控制系统（包括路由、管理、LLDP及ARP）运行于逻辑拓扑之上。分层架构的优势在于：第一层OCS设备对多数控制软件透明，这些软件仅感知逻辑第二层连接。

4.3 非最短路径路由

传统Clos拓扑通过脊柱上行下行路由自然支持负载均衡。然而直接连接拓扑存在 $n:1$ 的超额订阅，导致最坏情况 n 区块间的排列流量，采用最短路径分发机制将超额订阅比降低至2:1以应对最坏情况流量

需要采用非最短路径转发。对于均匀随机流量，可实现接近1:1的非阻塞通信，但需如图5所示对可用路径进行精细管理，并为部分区块预留带宽需求余量。虽然经由其他区块中转看似降低带宽效率，但我们识别出四种有益场景：

#1: 两个区块间的流量需求可能超过区块间直连路径的容量（图5 o 3）。

#2: 区块间流量可能不对称。强制所有流量经直连路径传输，意味着需为流量更大的方向构建双向容量（因双向容量对称性，参见§2中环行器约束）。

#3: 数据中心流量通常存在不同程度的不可预测波动性。通过将这种不确定性分散到多条路径（包括中转路径）上，可降低任何单一路径过载的概率（参见§4.4）。

#4: 在异构网络中，我们可选择通过另一个高速模块将流量从高速模块转发至低速模块（图9）。此方案虽会降低转发模块的总带宽，但能保留（首个）高速模块上的高速端口。不过如第6.1节所述，每个结构通常包含若干具备显著带宽冗余的模块，这些冗余资源可用于转发功能。

幸运的是，较大的区块基数（256或512）意味着我们可以构建网络拓扑结构，通过直接路径与中转路径的组合为每对区块提供高突发带宽。我们将流量工程限制在单跳（单中转）路径范围内，因为路径长度受限对基于延迟的拥塞控制（如Swift[19]）至关重要。更长的路径不仅降低带宽效率，还会增加无环路路由的复杂性并改变数据序列。需特别注意：单中转路径并不能自动避免路由环路。以路径 $A \rightarrow B \rightarrow C$ 与 $B \rightarrow A \rightarrow C$ 为例，若仅根据C的目标IP进行匹配，将导致A与B间形成环路。我们通过将源流量与中转流量分别隔离到两个虚拟路由转发（VRF）表中来消除环路。抵达面向DCNI端口但非本地目的地的数据包将标注至中转VRF。在此通过匹配目标IP，将数据包经由直连链路转发至目标区块。

4.4 流量感知路由

最初，我们采用了类似于Valiant负载均衡（VLB）[48]的需求无视型路由方案。该方案根据路径容量将流量分配至所有可用路径（直连与中转路径）。然而在此方案下，每个区块以2:1的超额订阅率运行，对于高利用率区块而言该比率过高（§6.3）。为避免此类区块超额订阅并提升整体网络吞吐量，我们基于实时流量数据优化不同路径的权重分配。通过流量计数器差分或数据包采样技术，从每台服务器收集流量测量数据。这些




图8：两种路由方案对比：(a) 需求完全分配至直连路径时预测MLU为0.5。

(b) 预测最大链路利用率为0.5，但需求在直连路径和中转路径间均等分配。(b)方案更具鲁棒性，当A与B间实际需求为4个单位时，其实现的MLU为0.75，而(a)方案仅达1.0。

每30秒将精细测量数据聚合形成区块级流量矩阵。每个条目 (i,j) 记录过去30秒内从区块 i 发往区块 j 的字节数。基于该流量矩阵流，我们维护

用于WCMP优化的预测流量矩阵。该预测流量矩阵由过去一小时内每个 (i,j) 对的峰值发送速率构成。在检测到流量矩阵1发生显著变化时，我们更新

1) 当检测到观测流量流中发生重大变化时，以及 2) 定期更新以保持其时效性。根据仿真结果，我们发现每小时刷新一次已足够[46]。

我们将路径权重优化问题建模为多商品流问题，其目标是在预测流量矩阵下最小化最大链路利用率（MLU）。我们发现MLU既是吞吐量的合理替代指标，也是衡量网络对流量模式变化适应能力的有效指标。根据经验，高MLU值表明大量链路面临过载风险，将导致数据包丢失、增加流完成时间[19]并降低网络吞吐量。我们的MLU模型未考虑因哈希算法缺陷或流量分布不均导致的并行链路负载均衡问题——这些链路连接两个数据块。实践表明此类简化对性能影响甚微（详见§D）。

理想情况下，预测矩阵应能紧密约束每对街区（商品）的交通需求。然而，30秒的交通轨迹1) 显示出较高的时变性，导致历史峰值往往无法预测未来峰值；2) 无法捕捉短于30秒的突发流量。因此，简单的公式化处理可能导致路径权重过度拟合于预测流量矩阵，从而降低其应对流量波动的稳健性。图8展示了一个说明性案例：两种WCMP方案对预测流量的最大单元长度（MLU）可能相同，但第二种方案通过利用更多路径多样性，使其对流量矩阵不确定性（即前述中转路由的第三个原因）更具鲁棒性。




图9：A和B为200Gbps区块，C为100Gbps区块。所有区块均配备500个端口。我们为每对区块分配250条链路以构建流量无关拓扑。该拓扑无法满足需求：A区块的总需求为80Tbps，而A区块的总带宽仅为75Tbps。采用流量感知拓扑可在200Gbps区块间分配更多链路（300条），从而提升A区块的总带宽并使A↔C部分需求可经由B中转。

我们在仿真和生产环境中均观察到预测值与实际MLU值的持续偏差，但不同商品间的偏差通常相互独立。因此，当某商品突发时，承载更多商品但每种商品占比更小的链路，其负载增幅小于承载商品较少但每种商品占比更大的链路。因此，尽管中转通常会增加网络负载，但我们发现其对流量预测误差的容忍度更高。

因此我们可以设想一个解决方案的连续谱：一端是通过最小化MLU和拉伸来匹配预测流量的优化方案，另一端则是类似VLB的解决方案——该方案不依赖需求预测，而是将流量平均分配到所有可用路径。连续谱上的各个点将在正确预测下的最优性与错误预测下的鲁棒性之间存在不同的权衡。我们观察到，尽管所有数据中心流量普遍存在不确定性，但不同网络结构因工作负载组合差异可能导致不可预测性程度不同。因此，我们设计了一种称为可变对冲的方案，使我们能够在该解决方案连续体上的不同点进行操作。根据实践经验，尽管不同网络结构因流量不确定性差异而存在最优对冲策略差异，但单一网络结构的最优值（§6.3）稳定性足以支持准静态配置。这种稳定性还允许我们通过评估近期流量轨迹，以离线方式低频次搜索最优对冲方案。可变对冲策略的详细公式详见附录B。

4.5 拓扑工程

在同速结构中，由于网络存在大量带宽冗余（§6.1, §6.2），均匀网络拓扑足以支撑实际生产环境中的流量模式。然而，我们仍需使拓扑结构与流量矩阵保持一致，以减少拓扑拉伸（图12）并防范尾部突发行为。

在异速结构中，统一网格拓扑可能因与低速节点配对导致过多链路降级，从而降低整体吞吐量

图9示例表明, 无流量意识的统一拓扑无法为4区块的流量需求提供足够聚合带宽, 而流量感知拓扑可轻松承载该负载。此外, 流量感知拓扑还能利用低利用率的高带宽链路——例如连接区块的链路——来优化资源分配。

速度模块充当“解复用器”, 将高速链路转换为多条低速链路。随着网络结构日益异构化, 以及高速(新型)模块成为主导负载贡献者, 这种优化方案的重要性日益凸显(图12)。

为优化流量感知拓扑结构, 我们采用联合建模方法, 将链路容量与路径权重作为决策变量, 以最大连通单元(MLU)和网络延展性作为优化目标。这种建模框架的协调性确保了流量工程优化能持续为拓扑结构产生良好效果。我们同时最小化与均匀拓扑的偏差——由此生成的网络在运维层面具有可预测性, 其结构近似均匀拓扑但具备更高吞吐量、更低拉伸度或兼具两者优势 (§6.3)。其他避免过拟合的技术已在[46]中探讨。我们认为该领域仍需深入研究。

4.6 流量与拓扑工程的协调整奏

当前, 流量工程与拓扑工程运行于截然不同的时间尺度。流量工程是内部

控制环路能以 O (秒)至 O (分钟)的粒度响应拓扑和流量变化, 具体取决于变更的紧急程度。我们要求这种优化级别

即使在最大规模的网络结构中, 该优化过程也需控制在数十秒内完成。拓扑工程的外层循环响应速度较慢, 且不处理故障或流量耗尽事件。当前实现新逻辑拓扑依赖于物理拓扑变更处理机制,

完成需耗时 O (小时)(§5)。

得益于OCS, 拓扑工程得以优化

与路由变更保持同步(或更快)。然而, 根据仿真结果, 我们发现每隔几周进行一次以上的块级拓扑重构所带来的收益有限[46]。这主要有两个原因:

1) 关于吞吐量, 大多数流量变化可通过路由机制充分处理。需要拓扑结构协助的流量变化往往发生得相当缓慢。2) 要使更频繁的拓扑结构重组发挥效益, a) 我们需要能够生成比长期流量预测更准确的短期流量预测, b) 短期预测必须与长期预测存在足够差异, 才能证明拓扑结构变更的必要性。历史上这两点均未实现, 因为多数不确定性源于流量在短期内的波动, 而长期趋势其实相当稳定。我们认为大规模机器学习工作负载将改变这一现状——它们不仅需要高带宽, 其流量模式也相对可预测。




图10: 新增两个聚合块的拓扑重构示意图。(a) 逻辑拓扑变更。

(b) 对应的交叉连接变更。




图11: 实现图10变更的增量式重布线。边标签显示双向链路数量。

5 实时结构重连

图10展示了最初由两个聚合块组成的网络结构, 这些块通过数据中心网络基础设施层的OCS设备相连, 并通过重新配置新增了两个块。支撑模块间逻辑链路的光路包含两类段落: 从模块收发器端口延伸至OCS交换机前面板的两条光纤链路, 以及连接这些链路的OCS内部交叉连接(详见图3)。添加两个模块需修改大量逻辑链路(图10(a)-右侧), 但底层光路变更仅需重新编程交叉连接——整个操作过程中连接至前面板的光纤均无需移动或修改(图10(b)-底部)。

常见网络操作均遵循此模式: 连接/断开整个模块或其附加基元与网络结构的连接, 调整模块间比例直连关系以实现拓扑工程 (§4.5), 甚至将网络结构从Clos转换为直连模式。得益于光交叉开关(OCS), 交叉连接可通过软件配置快速可靠地编程, 从而带来巨大的运营效益。Jupiter还支持对连接至前面板的光纤进行重新布线, 但此类手动布线操作仅适用于相对低频的操作场景, 或在

当面向前面板的线束不属于端到端链路时才进行。附录 (§E.2) 列出了此类操作的用例。

重新布线过程中的安全考量：尽管OCS显著简化了结构布线操作，但在运行中的结构上执行此操作需重点关注两项安全要点：维持可用性与性能服务水平目标（SLOs），并降低生产最佳实践的风险。

- **维持生产流量SLO**的核心在于确保网络所有切换点保持充足容量

为避免严重拥塞和数据包丢失，针对图10(a)-右侧的单次重连操作将导致容量大幅中断——因重连期间三分之二链路离线，且路由系统需适应新拓扑结构。然而采用增量式重连方案可保持更多容量在线。图11展示了针对图10变更的增量序列——在所有步骤中均保持A、B区块间至少10个双向容量单元（约83%），同时考虑了重连期间链路暂时不可用的情况。基于相同原理，在生产环境中我们可支持最小增量操作——每次仅需重新编程/布线单个OCS机箱，即使在高负载的网络中也能保障安全性。每次增量布线操作前后均设置流量疏导/恢复机制，确保布线过程零损耗。

- **避免独立故障域间的关联故障**，并限制操作的影响范围

在软件和运营层面，随着规模扩大，漏洞不可避免，因此重新布线至关重要。为实现这一目标，重新布线还需额外处理来自xml-ph-0000@deepl.internal到xml-ph-0000@deepl.internal区块的流量。

避免在多个故障域（DCNI和IBR）上同时操作，并确保对一个故障域的操作成功完成后再进行下一个操作，以避免失控列车场景中的级联故障。

§E.1 描述了生产网络中的重连工作流，包括：确定合适的重配置增量、修改前清空链路以实现每步无损重配置，以及强制执行等安全措施。

6 评估

6.1 流量特征

我们的生产流量矩阵在网络设计方面有两个突出要点：i) 区块间流量最适合用*引力模型*描述；ii) 不同区块间的流量负载存在显著差异。引力模型指出，任意两聚合区块间的流量需求与它们总需求的乘积成正比 (§C)。这种区块级流量趋势源于全网机器间通信的均匀随机模式[10]。引力模型使我们能够在异构网络结构中，为区块对分配链路数量提供基准决策依据。例如，通过计算

在同一结构中，一对20Tbps聚合块的容量与一对50Tbps聚合块的容量之比为4:25。我们发现，通常少数聚合块贡献了结构中绝大部分的负载。为量化这一现象，我们定义聚合块的*归一化峰值负载*（NPOL）为：该块峰值负载（99百分位）除以其容量所得的归一化值。接下来，我们分析了十个高负载结构中所有聚合块的NPOL分布，这些结构包含搜索、广告、日志、YouTube和云服务混合负载。每个结构的聚合块集均呈现NPOL分布特征，且所有分布均存在显著差异。事实上，十个结构中NPOL的变异系数（即标准差与均值之比）范围在32%至56%之间。每个结构中超过10%的块其NPOL低于该结构NPOL均值的一个标准差，而负载最轻的块NPOL<10%，这表明所有结构中大量闲置带宽，可用于承载中转流量。

6.2 直接连接结构的优化吞吐量与拉伸率

我们基于十个高负载结构评估了直接连接拓扑的优化吞吐量与扩展性

§6.1. 结构吞吐量指网络任何部分饱和前，其流量矩阵的最大扩展能力[17]。更高吞吐量意味着更低的最大链路使用率（MLU），从而为流量增长提供更大余量。为简化分析，我们仅考虑单

一流量矩阵：考虑单一流量矩阵 $T^{\max}$ 其中 $T^{\max}$ 为峰值流量

将流量从区块 i 重定向至区块 j 超过一周。我们选择其中一个

周数据以捕捉每日与每周的周期性峰值。

图12表明，在多数结构中，统一直接连接拓扑可实现最大吞吐量。流量感知拓扑在两种变速结构中进一步将吞吐量提升至上限值。仅4 结构未能达到该上限。下图

展示了xml-ph-0000@deepl.internal架构在不降低吞吐量前提下的最小扩展距离

$T^{\max}$ 的最小拉伸距离。在均匀直连拓扑中，拉伸距离更高，因为流量需求可能远超直连路径容量（这是选择中转的第一个原因）。

§4.3)。相比之下，流量感知拓扑工程允许大部分流量通过直接路径传输，其延迟值更接近1.0的下限。残余中转流量可归因于流量的不对称性和更高变异性 (§4.3)。作为对比，Clos拓扑因所有区块间流量均需经由主干区块中转，其延迟系数达2.0。上述结果基于对流量特性完全掌握的假设以界定性能极限。接下来我们将呈现更详尽的仿真结果及生产环境测量数据——其中流量分布并非 事先已知。

6.3 仿真结果

本节通过fabricD 实例，阐释直接连接模式下不同流量与拓扑工程设计的权衡关系。fabricD 是该网络中负载最重的节点之一，其速度异质性正因高负载而持续加剧。




图12：上图：10个交换结构中，采用统一直连与拓扑优化直连方案的吞吐量对比。吞吐量以理想上限值进行归一化处理，该上限假设存在完美的高速脊柱层，既消除链路速率降额，又能完美平衡各链路流量。下图：在相同吞吐量条件下，低速与高速交换块比例最优配置。

低速与高速模块比例及后者日益增长的流量。我们采用经验证可精准匹配实际生产环境 (§D) 的时间序列仿真，研究以下配置：1) 均匀拓扑下的需求无关路由 (VLB)；2) 采用较小缓冲区或更大缓冲区 (统一拓扑) 的流量工程 (TE)；4) 采用更大缓冲区 (拓扑工程ToE) 的TE。

3) 统一拓扑下采用更大对冲的TE，以及4) 拓扑工程 (ToE) 下采用更大对冲的TE。图13展示了四种配置下的最大延迟单元 (MLU) 时间序列及延展性。高MLU值表明VLB多数时间无法支撑流量 (下节将在低负载生产网络中验证此结论)。在流量感知路由下，更大对冲量虽能降低平均MLU并消除多数峰值，但需以更高延展性为代价。拓扑工程则可同时降低MLU与延展性。在聚合层面上，流量与拓扑工程下的第99百分位MLU (红色时间序列) 与第99百分位最优MLU的偏差小于15%。最优值假设存在完美的路由与拓扑结构，即每个时间快照点都能精确掌握流量状况。

不同面料的最大线用量与弹性之间的权衡关系各不相同，因此必须考虑特定面料的对冲系数。例如在G结构中，小对冲方案的99百分位MLU比大对冲方案低5%，平均伸展度低21%。这是因为G的流量更稳定且可预测，小对冲方案更侧重预测准确性的最优性，而非对预测误差的鲁棒性。不同结构存在差异，但在同一框架内，不同对冲水平下的MLU和stretch随时间推移具有稳定的排序，因此我们仅需在中进行低频重构/重新优化 (§4.4)。

6.4 生产实践

我们考察了Clos拓扑向直连拓扑转换的实例，以及统一拓扑向流量感知拓扑转换的实例。重点关注传输层的最小往返时延(min RTT)、流完成时间(FCT)和传输速率等指标，并比较转换前后的指标变化。针对每项指标，我们




图13：在不同流量和拓扑工程配置下的MLU时间序列，以在完全掌握流量信息时路由和拓扑下的峰值MLU为基准进行归一化。伸展度保持稳定，平均值见图例。

计算转换前后两周的每日中位数和第99百分位数。随后采用学生t检验

t检验判断变化是否具有统计学意义，并将 p 值 ≤ 0.05 的差异结果呈现在表1中。小流量数据的最小RTT和FCT对

路径长度，在从Clos拓扑转换为统一直连拓扑后得到缩短 (路径长度从2缩短至1.72)。启用拓扑工程后，最小往返时间 (Min RTT) 和最大往返时间 (FCT) 也得到缩短 (路径长度从1.64缩短至1.04)。更低的最小往返时间有助于提高传输成功率。转换为统一直连拓扑后，聚合块面向DCN的总容量提升57%，因移除低速主干消除了降额效应，使更多链路得以高速运行。受队列延迟主导的99百分位FCT要么降低要么统计上无变化，表明网络拥塞在转换后得到缓解或保持稳定。

为验证TE的优势，我们在中等负载的均匀直连结构上进行实验：关闭TE功能并运行VLB一天。实验期间，拉伸率从1.41升至1.96，总负载增加29%，尽管需求偶然下降8% (处于典型时间波动范围内)。

往返时延因拉伸率扩大与拥塞加剧而增长6-14%，第99百分位流控制时延因更严重的拥塞攀升至29%，平均丢弃率则激增89%。拥堵加剧，99百分位FCT最高增长29%，平均丢弃率上升89%。

基于OCS的结构布线重构：表2展示了在采用OCS的结构中，DCNI层布线重构速度相较于早期采用手动配线架 (PP) [49] 的方案在10个月周期内的提升幅度。OCS在中位数上实现9.6倍加速，均值上达3倍加速。由于OCS结构中更快的重连速度，其运营成本贡献扩大数倍。

	Clos到统一直连	统一到ToE直连
最小往返时延 50p	-6.89%	-11.02%
最小往返时间 99便士	-7.00%	-16.01%
FCT (小额交易) 50便士	-5.77%	-12.37%
FCT (小流量) 99便士	-24.22%	$p>0.05$
FCT (大流量) 50便士	-10.29%	$p>0.05$
FCT (大流量) 99便士	$p>0.05$	$p>0.05$
交付率 50便士	13.59%	$p>0.05$
配送率 99便士	36.35%	13.76%

表1：网络传输指标与丢弃率变化情况：1) 在同一结构中，将Clos拓扑转换为均匀直连拓扑，其延伸度从2降低至1.72；2) 在不同结构中，将均匀拓扑转换为拓扑工程化（ToE）直连拓扑，其延伸度从1.64降低至1.04。

	加速率	带OCS的关键路径操作	
	工作流	关键路径	
中位数	9.58 x	OCS%	PP%
平均	3.31 x	31.1%	8.4%
第90位 -%	2.41 x	27.0%	10.9%

表2：基于OCS和PP的DCNI结构间布线性能对比。

工作流软件 (§E.1) 在基于OCS的结构中处于重连关键路径，凸显出进一步优化的明显途径。我们正致力于将结构重配置能力集成至SDN控制器，这使我们能够以更高的速率安全地执行全结构重连，从而充分释放OCS在其中的潜力。

6.5 成本模型

现对比当前记录计划（PoR）部署架构（含直连拓扑、OCS及环形器）与等规模基准传统数据中心设计（采用Clos拓扑及基于PP的DCNI，但不含环形器）的成本。

图14展示了基于Clos或直接连接网络架构的成本模型中的组成部分。机架成本（图14 00）不计入结构成本，但其上层所有组件（01-05）均按适用情况纳入成本核算，包括汇聚区块交换机（假设两种架构中区块采用相同基数）、光模块、铜缆、光纤、机架外壳、OCS及脊柱交换机。同时我们还考虑了每种架构的标准化电力成本。

当前Jupiter PoR架构的资本支出成本为基准值的70%。直接连接方案虽能消除资本支出，使用04和05以及使用环形器的优势超过了在03中采用光交叉开关而非配线架的代价。




图14：Clos与直连变体网络结构成本模型中考虑的分层组件。

在03中使用PP替代OCSes可进一步降低资本支出。但该方案既无法减轻扩容时的运维负担，也无法实现基于流量模式的拓扑快速工程化。采用直连拓扑与环形器技术可分别将架构所需OCS端口减半。此外，OCS成本可分摊至多代聚合模块使用周期。因此实际中，PoR架构的真实资本支出成本介于基准值的62%至70%之间，具体取决于数据中心服务生命周期。

PoR架构的标准化功耗仅为基准值的59%。功耗降低主要源于直接连接架构中移除了脊柱交换机05及相关光模块。环形器作为无功耗的被动元件，而光交叉开关（OCS）的功耗可忽略不计。

这些估算值提供了相对于基准线在生产中实现的节约下限。基于OCS的扩展在时间和劳动力方面预计都将低于基于PP的扩展。通过OCS进行拓扑工程所带来的网络效率，既减少了网络容量的建设，又推迟了网络扩容，从而降低了部署成本。

6.6 系统复杂度

直接连接拓扑与流量工程的结合显著降低了成本，其性能与Clos结构相当甚至更优，但同时也大幅增加了系统复杂性。我们通过投入分析和调试工具来缓解这一问题。例如，我们依托基于网络状态和路由方案的记录回放工具来调试可达性和拥塞问题。根节点规划同样需要考虑动态中转流量。我们通过自动化分析降低了规划的难度。

7 相关研究

网络拓扑：基于Clos的拓扑[1, 2, 14, 24, 33]虽具备高度可扩展性，但在增量网络扩展[37]和路径长度方面并非最优解。Jellyfish[36, 37]采用非结构化拓扑以促进增量扩展，但代价是增加了布线复杂度、管理难度和路由设计复杂性。

直接连接拓扑结构[6, 18, 32, 45]，主要体现在高性能计算（HPC）领域，优化长距离传输

通过将高基数路由器聚合为虚拟路由器, Dragonfly+ [32] 实现了网络中链接的可达性, 从而提升网络有效基数并缩小网络直径。该方案采用混合架构: 各组内路由器采用克洛斯拓扑连接而非全连接网格, 而 FatClique [45] 则构建了由直接连接的团组构成的分层结构。Slim Fly [6] 通过求解近似解决度直径问题的图结构, 更接近理论最优网络直径。直接连接的Jupiter拓扑采用与Dragonfly+ [32]相似的混合方案, 将基于Clos拓扑的聚合块直接连接。相较于Dragonfly+的硬件自适应路由, Jupiter提供基于软件的流量工程方案, 可在传统商用硅芯片交换机上运行。借助 OCS 层, Jupiter 提供基于 SDN 的拓扑工程能力, 可根据流量模式动态调整拓扑结构——这是其相较其他直接连接网络的独特优势。此外, Jupiter 支持异构速率拓扑, 而传统 HPC 网络通常采用统一部署模式。据我们所知, 异构网络目前仅在最多包含两种交换机的理论模型中得到探索[36]。

可重构网络: 关于可重构互连的研究成果丰富[5, 9, 11, 13, 16, 22, 26, 27, 29, 43]。Helios[11]采用与本文提出的OCS层类似的方法, 通过混合电光开关实现动态拓扑, 但缺乏基于需求的精细化流量工程。RotorNet[27]则采用不同设计思路, 通过静态配置集交替切换OCS连接, 在所有端点间提供均匀带宽。该设计完全消除了对集中式控制平面的需求, 代价是在流量模式不均匀时会导致类似VLB的次优带宽利用率。

流量与拓扑工程: 部分关于需求感知路由的先期研究[44, 47]基于多重流量矩阵进行重构, 但专注于固定广域网的路由问题。与Jupiter更相似的近期研究, 则针对具有OCS互连的网络提出多种基于细粒度需求导向的拓扑与路由优化算法[8,40], 或基于高层次流量类型采用更粗粒度的优化方法[15]。Jupiter的流量工程与拓扑工程算法及更新节奏历经演进, 已成功扩展至具有高度可变流量的超大规模数据中心并获得生产环境验证。先前研究通过将流量波动转化为惩罚项[30]或在给定流量范围内提供性能保证[4], 开发出应对流量不确定性的鲁棒路由算法。虽然我们的设计考虑了类似因素, 但其建模更简洁且能处理不同层级的不确定性。其他路由技术或仅关注故障容错性[20, 38], 或采用

一种需求无关的方法[3], 其性能相对于需求感知方法较低。此前也有研究通过调整长途广域网光网络的拓扑结构来实现链路速率调节[35], 或通过评估信号强度优化跳数[34]。Jupiter主要基于流量模式提供分布式中心网络拓扑工程。我们假设链路维护旨在支持信号强度和比特误码率的预期质量 (§ E.1)。

8 结论

本文回顾了谷歌数据中心网络Jupiter近十年的演进历程。其核心在于基于MEMS的光学电路交换机、软件定义网络以及自动化安全运行这三大关键使能技术。依托这些基础技术, Jupiter蜕变为可增量部署的网络架构, 实现异构网络模块的协同共存与模块化更新。Jupiter最初采用标准Clos拓扑结构, 可为任意允许的流量模式提供最佳吞吐量。为释放生产网络的容量冗余并解决Clos结构中脊柱模块的技术更新难题, 我们将Jupiter演进为直连拓扑, 并针对观测到的模块级流量模式实现了动态流量与拓扑工程能力。相较传统Clos方案, 该架构在保持相当吞吐量的同时, 平均路径长度更短。

除可实现显著的资本支出和运营支出节约外。

若干未来方向仍是活跃的研究领域, 包括: i) 协同优化工作负载调度与网络流量及拓扑工程, 以实现可预测的端到端性能 (这对新兴高带宽机器学习工作负载至关重要); ii) 减少带宽闲置及其他优化措施, 以应对异构技术间的交互操作; iii) 扩展至校园及跨数据中心网络。我们的愿景是构建持续演进的虚拟数据中心级计算机系统, 通过动态流量与拓扑工程化网络, 实现计算、存储与机器学习的协同优化。

9 致谢

许多团队为谷歌数据中心网络技术的演进做出了贡献。我们特别要感谢网络基础设施团队、平台团队 (硬件与光通信)、软件质量保证团队 (SQA)、全球容量交付团队 (GCD)、数据中心运营团队、站点可靠性工程团队 (SRE) 以及项目管理组织 (PMO) 等团队。同时感谢我们的导师Rachee Singh, 以及匿名SIGCOMM审稿人提供的宝贵反馈。

参考文献

- [1] Mohammad Al-Fares, Alexander Loukissas, Amin Vahdat. 2008. 可扩展的通用数据中心网络架构。《SIGCOMM计算机通信评论》第38卷第4期（2008年8月），第63–74页。https://doi.org/10.1145/1402946.1402967
- [2] Alexey Andreyev, Xu Wang 与 Alex Eckert. 2019. 《重塑 Facebook 数据中心网络》. https://engineering.fb.com/2019/03/14/data-center-engineering/fl6-minipack/. *Facebook 工程博客* (2019).
- [3] David Applegate, Lee Breslau 与 Edith Cohen. 2004. 《应对网络故障：实现需求无关的最佳恢复的路由策略》。收录于ACM SIGMETRICS会议论文集。
- [4] David Applegate 与 Edith Cohen. 2003. 《增强域内路由对变化与不确定流量需求的鲁棒性：理解路由策略的基本权衡》。收录于ACM SIGCOMM会议论文集。
- [5] 希特什·巴拉尼、保罗·科斯塔、拉斐尔·贝伦特、丹尼尔·克莱瑟罗、伊斯特万·哈勒、克日什托夫·约兹维克、福蒂尼·卡里努、索菲·兰格、石凯、本·汤姆森、休·威廉姆斯. 2020. 天狼星：具备纳秒级光切换的扁平化数据中心网络。载于ACM数据通信特别兴趣组年度会议论文集：计算机通信应用、技术、架构与协议 (SIGCOMM '20)。
- [6] Maciej Besta 与 Torsten Hoefler. 2014. 轻量飞翼：一种经济高效的低直径网络拓扑结构。收录于SC'14：国际高性能计算、网络、存储与信息分析会议论文集。IEEE, 348–359.
- [7] 贝西·贝耶、克里斯·琼斯、詹妮弗·佩托夫与尼尔·墨菲. 2016. 《站点可靠性工程》。https://sre.google/books/. 谷歌工程技术系列丛书（2016）。
- [8] 曹培瑞、赵世振、张敏怡、刘云卓、王新兵. 2021. 《TROD：从电力数据中心向光数据中心的演进》。载于2021年IEEE第29届网络协议国际会议 (ICNP)。IEEE, 第1–11页。
- [9] 陈凯、安基特·辛格拉、阿图尔·辛格、基肖尔·拉马钱德兰、徐磊、张悦平、温希涛、陈岩. 2013. 《OSA：具备前所未有的互连灵活性的数据中心网络光交换架构》。IEEE/ACM网络交易会22, 2 (2013), 498–511。
- [10] William James Dally与Brian Patrick Towles. 2004. 《互连网络原理与实践》。Elsevier出版社。
- [11] N. Farrington, G. Porter, S. Radhakrishnan, H. H. Bazzaz, V. Subramanya, Y. Fainman, G. Papen, A. Vahdat. 2010. Helios：面向模块化数据中心的混合光电交换架构。收录于Proc. ACM SIGCOMM.
- [12] 安德鲁·D·弗格森、史蒂夫·格里布尔、洪志尧、查尔斯·埃德温·基利安、瓦卡尔·穆辛、亨里克·穆赫、翁俊、列昂·普蒂耶夫斯基、阿琼·辛格、洛伦佐·维奇萨诺等. 2021. 《猎户座：谷歌软件定义网络控制平面》。载于NSDI会议论文集，第83–98页。
- [13] 莫妮娅·戈巴迪、拉图尔·马哈詹、阿马尔·帕尼沙伊、尼希尔·德瓦努尔、贾纳尔丹·库卡尼、吉里贾·拉纳德、皮埃尔-亚历山大·布兰奇、侯曼·拉斯泰加尔、玛德琳·格利克、丹尼尔·基尔珀. 2016. 《Projector：敏捷可重构数据中心互连》。载于《2016年ACM SIGCOMM国际会议论文集》。216–229页。Projector：敏捷可重构数据中心互连。载于《2016年ACM SIGCOMM国际计算机通信会议论文集》。216–229页。
- [14] Albert Greenberg, James R. Hamilton, Navendu Jain, Srikanth Kandula, Changhoon Kim, Parantap Lahiri, David A. Maltz, Parveen Patel, and Sudipta Sengupta. 2009. VL2：可扩展且灵活的数据中心网络。载于ACM SIGCOMM 2009数据通信会议论文集 (SIGCOMM '09)。计算机协会，纽约州纽约市，51–62页。https://doi.org/10.1145/1592568.1592576
- [15] 陈·格莱纳、约翰内斯·泽瓦斯、安德烈亚斯·布伦克、曼雅·戈巴迪、斯特凡·

施密德、陈·阿文. 2021. 《地狱犬：数据中心拓扑设计中的选择力量——吞吐量视角》。ACM计算系统测量与分析会议论文集5, 3 (2021), 1–33。

- [16] N. Hamedazimi, Z. Qazi, H. Gupta, V. Sekar, S. R. Das, J. P. Longtin, H. Shah, A. Tanwer. 2014. FireFly: 基于自由空间光学的可重构无线数据中心 结构. 收录于*ACM SIGCOMM会议论文集*.
- [17] S. A. Jyothi, A. Singla, P. B. Godfrey, 和 A. Kolla. 2016. 网络拓扑吞吐量的测量与解析. 收录于《*高性能计算国际会议论文集: 网络、存储与分析 (SC)*》。
- [18] John Kim, Wiliam J Dally, Steve Scott, Dennis Abts. 2008. 《技术驱动的高可扩展性蜻蜓拓扑结构》. 载于《*2008年国际计算机体系结构研讨会论文集*》. IEEE出版社, 77–88页.
- [19] Gautam Kumar、Nandita Dukkupati、Keon Jang、Hassan M. G. Was-sel、Xian Wu、Behnam Montazeri、Yaogong Wang、Kevin Springborn、Christopher Alfeld、Michael Ryan、David Wetherall 与 Amin Vahdat。2020。Swift: 数据中心拥塞控制中简单有效的延迟策略。收录于*ACM数据通信特别兴趣组年度会议论文集: 计算机通信应用、技术、架构与协议 (SIGCOMM '20)*。计算机协会, 纽约州纽约市, <https://doi.org/10.1145/3387514.3406591>
- [20] 普拉文·库马尔、杨元、克里斯·于、内特·福斯特、罗伯特·克莱因伯格、彼得·拉普霍夫、林俊林、罗伯特·索尔。2018。《半 遗忘 流量工程: 未选择的路》。载于《*NSDI会议论文集*》。
- [21] 李伟强、王锐、张建安。2022。《数据中心网络布线配置》。美国专利 11,223,527。
- [22] 刘赫、马修·K·穆克吉、李聪龙、尼古拉斯·费尔特曼、乔治·帕彭、斯特凡·萨维奇、斯里尼瓦桑·塞尚、杰弗里·M·沃尔克、大卫·G·安德森、迈克尔·卡明斯基、乔治·波特、亚历克斯·C·斯诺伦。2015。《混合电路/分组网络调度技术》。载于*ACM CoNEXT会议论文集*。
- [23] 刘红、浦田亮平、周翔、阿明·瓦赫达特。2020。《*数据中心网络需求演进与发展趋势*》。斯普林格光学网络手册系列。
- [24] Vincent Liu, Daniel Halperin, Arvind Krishnamurthy, and Thomas Anderson. 2013. F10: 一种容错工程化网络. 载于*第十届USENIX网络系统设计与实现研讨会 (NSDI 13)*。USENIX协会, 伊利诺伊州伦巴德, 399–412. https://www.usenix.org/conference/nsdi13/technical-sessions/presentation/liu_vincent
- [25] Nick McKeown, Tom Anderson, Hari Balakrishnan, Guru Parulkar, Larry Peterson, Jennifer Rexford, Scott Shenker, and Jonathan Turner. 2008. OpenFlow: Enabling Innovation in Campus Networks. *ACM 计算机通信评论* 38 (2008), 69–74. 第2期. <https://doi.org/10.1145/1355734.1355746>
- [26] William M. Mellette, Rajdeep Das, Yibo Guo, Rob McGuinness, Alex C. Snoeren, George Porter. 2020. 跨时域扩展实现 带宽效率与低延迟. 收录于*NSDI会议论文集*。
- [27] William M Mellette, Rob McGuinness, Arjun Roy, Alex Forencich, George Papen, Alex C Snoeren, and George Porter. 2017. Rotornet: 可扩展、低复杂度的光数据中心网络. 收录于*ACM数据通信特别兴趣组会议论文集*. 267–280.
- [28] Jeffrey C. Mogul、Drago Goricanec、Martin Pool、Anees Shaikh、Douglas Turk、Bikash Koley 与 Xiaoxue Zhao。2020。多抽象层级网络拓扑建模实践。第 十七 届 网 络 系 统 设 计 与 实 现 研 讨 会 (NSDI) 。 <https://www.usenix.org/conference/nsdi20/presentation/mogul>
- [29] 乔治·波特、理查德·D·斯特朗、内森·法灵顿、亚历克斯·福伦奇、孙骥辰、塔雅娜·罗辛、耶沙亚胡·费恩曼、乔治·帕彭和阿明·瓦赫达特。2013。《将微秒级电路交换 集成到数据中心》。载于*ACM SIGCOMM会议论文集*。
- [30] 马修·罗芬、米克尔·托鲁普、张寅。2003。《基于估计流量矩阵的流量工程》。载于*第三届ACM SIGCOMM互联网测量会议论文集*. 248–258页。

- [31] R.莱夫、J.金、JP.希基、A.格瑞克、D-卡尔、F.帕尔多、C.博勒、R.弗拉姆、N.巴萨万哈利、C.约等。2001。《1296端口MEMS透明光交叉连接器：2.07拍比特/秒交换容量》。载于《*光 光纤通信会议*》。美国光学学会，PD28。
- [32] 亚历山大·什皮内尔、扎基·哈拉马蒂、萨尔·埃利亚德、弗拉基米尔·兹多尔诺夫、巴拉克·加夫尼和埃坦·扎哈维。2017。《Dragonfly+：适用于扩展数据中心的低成本拓扑结构》。载于2017年IEEE第三届极端规模与大数据时代高性能互连网络国际研讨会 (HiPINEB)。IEEE，第1-8页。
- [33] 阿琼·辛格、容俊、阿米特·阿加瓦尔、格伦·安德森、阿什比·阿米斯德、罗伊·班农、塞布·博文、高拉夫·德赛、鲍勃·费尔德曼、保利·杰尔马诺、阿南德·卡纳加拉、刘汉英、杰夫·普罗沃斯特、杰森·西蒙斯、丹田英一、吉姆·万德勒、乌尔斯·霍尔茨勒、斯蒂芬·斯图尔特和阿明·瓦赫达特。2015年。《木星崛起：谷歌数据中心网络中封闭拓扑与集中式控制的十年演进》。载于SIGCOMM '15。
- [34] Rachee Singh, Nikolaj Björner, Sharon Shoham, 殷亚伟, John Arnold, Jamie Gaudette. 2021. 《基于Shoofly的广域网经济高效容量配置》. 收录于《2021年ACM计算机科学与技术协会国际会议论文集》 (SIGCOMM 2021 Conference), 第534-546页。
- [35] 拉奇·辛格、曼雅·戈巴迪、克劳斯·蒂科·福斯特、马克·菲勒、菲利普·吉尔。2018。《RADWAN：速率自适应广域网》。载于《2018年ACM计算机网络与数据通信专业组会议论文集》。547-560页。
- [36] 安基特·辛格拉、P.布莱顿·戈弗雷、亚历山德拉·科拉。2014. 高吞吐量数据中心拓扑设计. 载于第11届USENIX网络系统设计与实现研讨会 (NSDI 14)。29-41。
- [37] A. Singla, C.-Y. Hong, L. Popa, P. B. Godfrey. 2012. 水母：随机网络数据中心 (Jellyfish: Networking Data Centers Randomly). 收录于USENIX NSDI会议论文集。
- [38] Martin Suchara, Dahai Xu, Robert Doverspike, David Johnson, and Jen-nifer Rexford. 2011. 网络架构实现故障恢复与流量工程. 收录于ACM SIGMETRICS会议论文集。
- [39] 宋宇伟、铁晓正、黄斯基、曾宏毅。2016。《Robotron：Facebook规模的自上而下网络管理》。收录于2016年ACM SIGCOMM会议论文集 (SIGCOMM '16)。美国计算机协会，纽约州纽约市，426-439页。
<https://doi.org/10.1145/2934872.2934874>
- [40] Min Yee Teh, Shizhen Zhao, Peirui Cao, Keren Bergman. 2020. COUDER：面向数据中心网络的光电路交换拓扑工程方案. *arXiv预印本 arXiv:2010.00090* (2020).
- [41] 浦田亮平、刘红、安村凯文、毛尔吉、吉尔·伯杰、周翔、林思迪克、罗伊·班农、达伦·哈钦森、丹尼尔·尼尔森、列昂·普蒂耶夫斯基、阿琼·辛格、翁俊、阿明·瓦赫达特。2022。《阿波罗计划：实现数据中心规模的光学电路交换》。arXiv。
- [42] 浦田亮平、刘红、周翔、阿明·瓦达特。2017。《数据中心互连与网络：从演进到整体性变革》。载于《2017年光纤通信会议 (OFC) 论文集》。
- [43] 王国辉、David G Andersen、Michael Kaminsky、Konstantina Papagiannaki、TS Eugene Ng、Michael Kozuch、Michael Ryan。2010。《c-Through：数据中心中的兼职光通信》。收录于ACM SIGCOMM 2010会议论文集。327-338页。
- [44] 王昊、谢海勇、邱莉莉、杨理查德、张寅、阿尔伯特·格林伯格。2006。《COPE：动态网络中的流量工程》。收录于ACM SIGCOMM会议论文集。
- [45] 张明阳、拉迪卡·尼兰詹·迈索尔、苏查·苏皮塔亚蓬、拉梅什·戈温丹。2019。《理解数据中心拓扑结构的生命周期管理复杂性》。载于NSDI会议论文集。
- [46] 张明阳、张建安、王瑞、拉梅什·戈温丹、杰弗里·C·莫古尔、阿明·瓦赫达特。2021。《双子星：具备拓扑与流量工程的实用可重构数据中心网络》。arXiv:cs.NI/2110.08374
- [47] Y. Zhang 和 Z. Ge. 2005. 关键流量矩阵的识别. 载于2005年国际可靠系统与网络会议 (DSN'05)。

SIGCOMM'22, 2022年8月22日至26日, 荷兰阿姆斯特丹

[48] 张申、McKeown. 2005. 基于Valiant负载均衡的可预测互联网骨干网设计. 收录于*IEEE IWQoS会议论文集*.

[49] 赵世振、王瑞、周俊兰、王俊、Jeffrey C Mogul、Amin Vahdat. 2019. 最小重连: 面向闭合数据中心网络的高效在线扩展. 收录于*第16届USENIX网络化计算系统设计与实现研讨会 (NSDI 19)*。221–234.

[50] 周俊兰、马尔维卡·特瓦里、朱敏、阿卜杜勒·卡巴尼、列昂·普蒂耶夫斯基、阿琼·辛格、阿明·瓦赫达特. 2014. WCMP: 数据中心公平性改进的加权成本多路径技术. 载于《*第九届欧洲计算机系统会议论文集*》(EuroSys '14)。美国计算机协会, 纽约州纽约市, 第5篇, 14页。
<https://doi.org/10.1145/2592798.2592803>

附录

附录为未经同行评审的补充材料。

A 聚合块设计选择

木星[33]的首个汇聚模块采用三层交换机架构，第一层由ToR设备构成，第二层与第三层则划分为8个独立模块（称为中间模块或MB）。此后我们为后续代木星汇聚模块统一采用通用型四MB三层交换机架构。

图15（上）展示了汇聚模块的通用设计。为实现冗余，设有4个独立的中间模块，每个模块部署于物理机架中，内部通过阻塞拓扑结构将两级交换机相互连接。

这些MBs总共可提供最多512条连接至ToR的链路，以及最多512条连接至DCNI层的链路。聚合模块内的链路可根据数据包交换机的代际差异，运行于40G（4×10G通道）、100G（4×25G通道）或200G（4×50G通道）速率，并规划未来升级至400G（4×100G）和800G（4×200G）速率。

图15（底部）展示了区块内流量（紫色）、通过直接跨区块路径（青色）以及通过中间聚合区块（粉色）实现的跨区块流量的网络路径。通过结合流量工程与拓扑工程，针对跨区块流量模式优化拓扑结构和路由（转发路径），从而最大化直接青色路径并最小化粉色路径。

选择三层聚合块拓扑而非扁平的两层拓扑有两个原因。首先，配备4个全互联管理背板（MB）可使顶层交换机（ToR）上行链路以4的倍数部署，从而根据机架内ToR下方的计算/内存/存储资源灵活配置带宽。而采用扁平化两级聚合块拓扑时，每个ToR必须连接所有聚合交换机（而非仅连接4个多板卡交换机），导致ToR上行链路配置的灵活性降低。

其次，每个聚合块内的两个阶段使该聚合块能够连接到结构中其他聚合块中的所有对应聚合块。这使得中间聚合块中的"中转流量"能够通过聚合块内部跳转（而非如图15中粉色路径所示全程到达边缘交换机）到达任意目标聚合块。




图15：上图展示了通用聚合块设计，其采用四端口（中间块或MB）与三交换机阶段架构（ToR、第二阶段、第三阶段）。每个ToR交换机通过N条上行链路（ $N=1,2,4,\dots$ ）连接至所有中间块。

下图展示了区内流量（紫色）的网络路径，以及通过直接跨区块连接实现的跨区块流量路径。

路径（青色）以及通过中间聚合块（粉色）的出口流量需求。

要求中转流量通过ToR节点跳转是不理想的，因为ToR节点是按需逐步部署的，且ToR到MB的链路平衡性不如网络层级更高（如第二层到第三层）的链路。流量工程控制器会监控每个MB的剩余带宽，并为中转流量优化使用最 的闲置聚合块。

B 可变对冲公式

从宏观层面看，我们通过在基础多商品流模型中引入额外约束来实现对冲，迫使商品沿多条区块级路径运输。每种商品都配有一组不相交路径（直达路径与单次中转路径）。路径容量用 C_p 表示，即构成该路径的一个或两个区块级边所能承载的最小容量。将构成路径的两个区块级边进行求和。

两个区块级边所构成的路径的最小容量。将所有路径容量相加即为

商品在所有路径上的容量之和构成突发带宽： $B = \sum_p C_p$ 。设商品的输入负载为 D ，路径分配决策变量为 x_p ，则 $\sum_p x_p = D$ ，即所有输入负载必须被分配。我们引入参数Spread，记为 S ，其中 $S \in (0,1]$ ，用于表示商品必须分散使用的突发带宽比例。具体而言，对冲约束可表述为： $x_p \leq D \cdot \frac{C_p}{B}$ 。需注意当 $S=1$ 时，若要完全满足提交负载，则 $x_p = D \cdot \frac{C_p}{B}$ 。

$B \cdot S$

B

该方案退化为需求无关分配（类似于VLB），其中每种商品（无论提供负载如何）均按路径容量比例分配至可用路径。当 S 趋近于0时，对冲约束将解除，使模型退化为经典的多商品流模型多商品流问题。这些特性使我们能够通过调整 S 在两个极端点之间灵活操作。

我们尝试的其他公式化方案旨在避免过拟合，例如这些方案要么扩展性差，要么无法让我们针对不同工作负载和网络架构（或两者兼顾）明确权衡最大负载单元（MLU）与扩展性。例如，旨在为每种商品最大化余量的方案往往倾向于高扩展性，即使流量不确定性较低时亦如此，且其求解时间过长——即使在小型网络架构中也是如此（）。

C 重力流量模型验证与网络吞吐量

若机器间通信具有均匀随机性，则区块间总流量遵循引力模型。我们通过比较测量流量矩阵 D 中的区块间流量需求与基于引力模型生成的流量矩阵，验证了引力模型可近似描述区块间流量。需注意，该模型假设流量矩阵为随机矩阵，且其元素仅取自引力模型生成的流量矩阵。 D' 进行验证。需注意：

$D'_{ij} = E_i \cdot E_j / L$ ，其中 E_i 分别表示出口流量需求在路径（青色）上

I_j 表示区块 j 的入站流量需求。在图16中，我们分别将 D_{ij} 与 D' （以 D 中的最大条目归一化）及 D' 进行比较，需求估计的均方根误差为0.05。测量流量矩阵 $\{D\}$ 包含十个结构中各100个30秒粒度的流量矩阵。




图16：每个点代表一对区块间估计流量需求（x轴）与测量需求（y轴）。虚线对应完美估计。

我们证明：当所有模块具有相同速率和基数，且流量矩阵遵循重力模型且对称时，均匀直连拓扑可支持与克洛斯特拓扑相同吞吐量。首先证明若存在

若网络支持对称重力模型流量矩阵, 则当节点聚合流量减少时, 该网络同样支持该流量。需注意, 根据重力模型, 当xml-ph-0000@deepl.internal的总流量减少时, 非该节点起始或终点的商品流量将增加。

u 的货物数量会随着 u 节点总流量的减少而增加。

引理1. 若网络 $G(V, E)$ 能支持重力模型流量矩阵 (其中区块出站与入站总流量需求相等, 且由 $\{D_i, \forall i \in V\}$ 给出), 则 $G(V, E)$ 也能支持某节点总需求降低后的流量, 即区块总需求由

, 即区块聚合需求由以下公式给出:
 $\{D_i, \forall i \in V \setminus u\} \quad \{D_u : D'_u < D_u\}$.

证明。给定区块聚合流量需求 $\{D_i, \forall i \in$

$V\}$, 则从 i 到 j 的流量需求为 $D_{ij} = D_i D_j / \sum_{k \in V} D_k$ 基于重力模型。当 u 至 D' 的需求递减时, i 至 u 的需求减少

$$c_{iv} = \frac{D_i D_v}{\sum_{k \in V} D_k} - \frac{D_i D'_v}{\sum_{k \in V} D_k + D'_v - D_v}.$$

i 到 j 的需求增加

$$b_{ij} = \frac{D_i D_j}{\sum_{k \in V} D_k} - \frac{D_i D_j}{\sum_{k \in V} D_k + D'_v - D_v}.$$

若 $c_{iv} > \sum_{j \in V \setminus \{i, v\}} b_{ij}$, 则来自 i 除 v 外的所有节点需求均可经由 v 传输, 因 i 到 v 的流量减少释放出足够容量。

剩余工作是证明 $c_{iv} > \sum_{j \in V \setminus \{i, v\}} b_{ij}$ 成立于

所有 $i \in V \setminus \{v\}$ 。

$$\begin{aligned} c_{iv} - \sum_{j \in V \setminus \{i, v\}} b_{ij} &= \frac{D_i D_v}{\sum_{k \in V} D_k} - \frac{D_i D'_v}{\sum_{k \in V} D_k + D'_v - D_v} \\ &\quad - \sum_{j \in V \setminus \{i, v\}} \left(\frac{D_i D_j}{\sum_{k \in V} D_k} - \frac{D_i D_j}{\sum_{k \in V} D_k + D'_v - D_v} \right) \\ &= \frac{D_i}{\sum_{k \in V} D_k} + \frac{\sum_{j \in V \setminus \{i, v\}} D_j}{D_v} \\ &\quad - \frac{D_i}{\sum_{k \in V} D_k + D'_v - D_v} D'_v + \sum_{j \in V \setminus \{i, v\}} \frac{D_j}{\sum_{k \in V} D_k + D'_v - D_v} \\ &= \alpha \frac{D_i}{D_j (\sum_{k \in V} D_k + D'_v - D_v)} \\ &\quad - \left(\frac{D_i}{\sum_{k \in V} D_k} + \frac{\sum_{j \in V \setminus \{i, v\}} D_j}{\sum_{k \in V} D_k + D'_v - D_v} \right) \\ &= \alpha D_i (D_v - D'_v) \\ &\geq 0, \end{aligned}$$

其中

$$\alpha = \frac{D_i}{\left(\sum_{k \in V} D_k \right) \left(\sum_{k \in V} D_k + D'_v - D_v \right)}.$$

□

考虑一组对称流量矩阵 $D = \{D(t)\}$, 其中 $D(t)$ 表示时间 t 节点间的流量需求, 遵循重力模型。设 $D_i(t)$ 表示时间 t 节点 i 的总流量。令 $D_i = \max_t D_i(t)$ 。我们证明静态网络拓扑能够支持所有流量。

采用动态流量感知路由。

定理2. 静态网络拓扑 G 可支持 D 中所有流量矩阵。在 G 中, i 与 j 间的链路容量由 $u_{ij} = D_i D_j / \sum_{k \in V} D_k$ 给出。

证明。考虑 $D^{\max}$ 其中所有节点均具有最大聚合流量需求 $D_i, \forall i \in V$ 。网状拓扑 G

其中链路容量 $u_{ij} = D_i D_j / \sum_{k \in V} D_k, \forall i, j \in V$ 支持

所有商品通过直接路径运输。我们证明 G 能够支持 $D(t), \forall t$ 通过归纳法证明。

对于时间 t , 考虑遵循以下规则的交通矩阵 $D^n(t)$:

重力模型, 且 $D^n(t) = D_x(t), x = 1, 2, \dots, n, D^n(t) = D_{n+1} \times n + 1, n + 2, \dots, |V|$ 。我们证明 G 能够 support $D^n(t), \forall n \in 1, 2, \dots, |V|$ 。根据引理 1, 若

G 支持 $D^n(t)$, 则 G 支持 $D^{n+1}(t)$, 因为聚合单节点聚合流量需求从 D_{n+1} 减少至 $D_{n+1}(t)$ 。鉴于 G 支持 $D^0(t) = D^{\max}$, G 支持 $D^n(t), n = 1, 2, \dots, |V|$, 包括 $D(t)$ 。□

$$u = \frac{D_i D_j}{\sum_{k \in V} D_k} = D_{ij}$$

即节点 i 的最大聚合流量。换言之, 当所有节点聚合流量需求满足

不要超过其容量。相比之下, Clos 拓扑结构在所有节点聚合流量

需求不超过其容量。在所有区块完全相同的特殊情况下, 各节点均匀

网络拓扑支持统一流量矩阵, 其中节点总流量等于其容量。根据定理

2. 当所有节点聚合流量需求均未超过其容量时, 均匀网络拓扑可支持所有流量; 且当流量矩阵为对称矩阵并遵循引力模型时 ()

。

D 仿真方法论

我们依靠仿真来指导我们的交通和拓扑环境

工程设计, 重现生产网络状态以进行诊断和调试, 并运行假设分析以优化生产变更。模拟基础设施至关重要

由于 1) 构建物理测试平台以匹配我们网络架构和工作负载的规模与多样性并不现实, 2) 在生产环境中直接探索不同设计或回答假设性问题既风险又耗时, 3) 网络状态过于复杂难以数学建模。

为使仿真可操作, 我们进行以下仿真扩展:

:

• 网络拓扑结构。我们将木星拓扑抽象为

块级简单图, 每个顶点代表一个




图17：测量链路利用率与模拟链路利用率之间的误差直方图。

每个块及其所有边代表连接两个块的所有链路。因此每个块被简化为具有256或512端口的抽象交换机。假设边上的流量在构成该边的链路间实现完美负载均衡（即使这些链路跨越不同源节点和目标节点）。

物理交换机）。

- **流量。**我们基于30秒粒度的流量轨迹对网络进行仿真。如前所述，流量矩阵条目记录源区块在30秒内向目标区块发送的字节数。该流量矩阵被视为该时间点的输入负载。

- **理想负载均衡与稳态假设。**我们假设输入负载被精确分配至多条路径

对WCMP权重进行调整。因此我们忽略了以下三方面的误差：1) 流量规模差异；2) 哈希算法的不完美性；3) WCMP权重缩减[50]。虽然我们严格按照生产环境配置运行流量预测、路由优化和拓扑优化循环，但未模拟网络路由由编程时的瞬态状态（拓扑转换因耗时较长仍进行模拟）。换言之，我们假设从一种转发状态切换到下一种状态时延迟为零。

尽管存在这些简化，模拟链路负载与实测值仍高度吻合。模拟与实测链路利用率的均方根误差(RMSE)小于0.02，该精度完全满足前述应用场景需求。通过这些简化措施，我们得以独立并行模拟每个流量矩阵，从而在数小时内完成对整个车队长达数月的模拟。

图17展示了测量链路利用率的误差直方图与模拟链路利用率的对比。样本由

超过百万个数据点，对应六种结构中不同时间段（跨度一个月）的链路。误差值集中在零点附近且幅度较小，这证明了模拟的准确性。

E 实现网络架构重构

本文阐述了将第5节所述高阶结构重连方法转化为自动化工作流的实现方案，并重点阐释了需要对OCS前端光纤链路进行重连的典型应用场景。




图18：拓扑变更 workflow。

E.1 重连 workflow

图18展示了实现重新布线的工作流程

在步骤^①中，求解器利用预期结构状态（例如模块集、其平台类型、基数，以专有意图表达语言表示）和流量矩阵（用于拓扑工程 §4.5）生成目标拓扑，该拓扑需满足物理约束（如DCNI和聚合块交换机的基数）及逻辑目标，例如跨故障域平衡链路负载和实现期望的成对块互联性。求解器同时利用当前拓扑²在实现预期状态的同时最小化差异[49]。

根据网络规模、预期状态变化及差值最小化可行性，当前拓扑与目标拓扑间的差异可能从数百条链路到数万条链路不等。

步骤2，阶段选择，通过逐步从当前拓扑结构中减去越来越小的差值分区（1、1/2、1/4、1/8等），确定安全过渡到目标拓扑所需的增量次数。基于残余网络的近期流量水平模拟路由和利用率，评估网络能否为各类流量维持服务水平目标（SLOs）。我们将划分单元与DCNI的域及其机架级子域对齐——这种与故障域的自然对齐可有效降低风险。

工作流为每次递增执行一系列步骤，

首先构建增量后的拓扑结构^③，通过无码方式将链路流量排空^③ 差分中当前拓扑模型^④——我们执行额外的安全

通过类似于阶段选择步骤的分析检查，确保后排网能承载流量并满足服务水平目标（SLOs）。链路的验证与排空对无损重配置至关重要。一旦

² 当前和目标拓扑以可表达的机器可读格式（例如[28, 39]）呈现，以便在工作流后期阶段对拓扑进行推理，同时配置和管理生成的网络结构。

³ 无中断流量转移是SDN功能之一，通过预先编程替代路径实现在将数据包从受影响的网络元素上原子性地转移之前，预先编程替代路径。

在受影响链路安全排空后, 我们将模型化的后递增拓扑^{o5}并分发配置

至SDN控制器^{o6}。通过后增量拓扑, 控制器可合理配置链路速率并分发LLDP数据包, 从而在重新布线阶段检测任何接线错误^{o7}。

交叉连接的重新布线是通过DCNI域 (§4.2) 中的SDN控制器进行软件配置来实现的, 这些控制器随后对OCS交换机进行编程。当形成新的端到端链路时, 工作流会执行链路鉴定, 包括通过比特误码率测试^{o8}来确认正确的逻辑相邻关系、光电电平和链路质量。工作流要求某阶段90%以上的链路成功通过认证后方可进入下一步⁴。链路建立后立即解除排水状态, 当成功建立且解除排水的链路达到阈值数量时, 即进入下一个增量阶段。作为性能优化措施, 与建模^{o3}及排水影响分析^{o4}相关的步骤下一阶段可与步骤^{o6}至^{o9}并行推进

当前阶段。所有阶段完成后, 我们将等待最终修复操作处理迭代过程中遗留的断链, 随后结束整个流程。

所有工作流步骤均由持续循环监控覆盖, 该监控实时监测流量、结构、Orion控制器健康状态及其他"紧急停止"信号。一旦检测到异常, 可预先终止当前步骤, 甚至启动自动回滚。我们同时强制执行跨结构故障域及跨集群的操作节奏控制——此

确保所有遥测数据均已同步完成

面对变更时, 安全循环机制可介入阻止级联故障。网络管理API系统层 (图7) 实现了工作流与SDN控制平面及数据平面的分离, 并强制执行安全约束。网络管理服务按区域故障域进行分片, 采用渐进式部署和影子启动技术[7], 以防止该关键层出现缺陷及相关故障。

表2中将步骤^{o1}-^{o5}归为工作流开销,

而其他步骤则被视为核心重新布线步骤的一部分。重新布线的端到端加速不包括最终修复步骤^{o11}。

E.2 前面板重新布线

以下操作需要在数据中心机房操作人员的协助下, 通过前面板进行连接性变更:

- **新增模块或基数升级。** Jupiter为未来模块预留空间和电源, 同时还需预先安装预留位置的光纤。
需预先铺设光纤至预留位置

⁴ 链路可能因布线错误、插头未插紧、灰尘或线缆/光纤老化等因素导致无法通过更严格的测试。我们倾向于将维修纳入工作流程, 因为必须恢复网络容量才能进行下一步操作, 且数据中心技术人员在此期间随时待命, 从运维角度更为便捷。

至DCNI交换机。但为最小化拓扑变更在SDN控制器部署后, 聚合块 (及光模块) 将随后部署当需要时。新增链路在逻辑重连步骤之前就已物理连接至DCNI交换机 (如图10(b)底部所示的"预部署"状态)。块的移除遵循相反顺序——首先通过逻辑重连将块从结构中断开, 然后再从DCNI层物理断开。

- **DCNI扩展。** DCNI层遵循Jupiter聚合模块的增量部署模型 (参见第3.1节)。
新增OCS机箱需重新平衡数据包交换机至整个DCNI层的链路, 这必然涉及前面板的物理重接线。
- **故障修复与技术升级。** 修复错接链路、损坏的光模块、光纤芯、OCS端口及机箱时, 均需
前前面板的变更。这些变更通常在就地修复, 即在DCNI上链接的落点处进行修复
机箱保持不变。

对于手动操作 (例如所有前面板重新布线), 应最大限度地提高增量重新布线步骤的空间局部性。这种局部性使运维人员能够在特定步骤内完成工作, 无需在数据中心内长距离移动, 从而最大化生产效率并降低出错概率。通过将物理相邻的OCS机箱纳入工作流序列, 即可实现此局部性。当重新布线步骤 (图18中的^{o7}) 涉及人工操作时, 工作流提供了一种基于Web的用户界面为运维人员提供实时协助与诊断支持, 这进一步提升了 的生产效率并降低了错误发生概率。

F 硬件组件

我们开发了三个关键硬件组件: 光交换中心 (OCS)、波分复用收发器 (WDM transceivers) 和光环形器 (optical circulators), 以实现成本效益高的大规模光交换层/分布式光网络互连 (DCNI) [41]。

%0.1 帕洛马 OCS

在部署的前几年, 数据中心网络基础设施层采用了基于供应商的开放式通信服务 (OCS) 解决方案。然而, 由于该方案在规模化部署中难以维持可靠性和质量, 最终决定自主开发一套OCS系统。

图19展示了帕洛马OCS的高级光学设计与工作原理。输入/输出光信号通过二维 (2D) 光纤准直器阵列进入光学核心。每个准直器阵列由N×N光纤阵列与二维透镜阵列构成。光核心包含两组二维MEMS反射镜阵列。如图19绿色线条所示, 每路带内光信号需依次穿过各准直器阵列的端口及两组MEMS反射镜。

19所示。通过驱动倾斜镜片, 将信号切换至对应的输入/输出准直光纤。整个端到端光路具备宽带互易特性, 以实现数据




图19：帕洛马OCS光核的设计与光路示意图。绿色线条标示带内光信号路径。与带内信号路径叠加的850nm波长监测通道（红色箭头）用于辅助镜片调谐。

在OCS系统中实现速率无关且双向的通信。与带内信号路径叠加的监测通道（图19中红色条形）有助于镜片的调谐。

每个MEMS阵列均注入850纳米波长的光。反射的监测信号随后被匹配的摄像头模块接收。伺服系统利用摄像头图像反馈优化MEMS驱动，以实现光信号路径的最小损耗。每组注入/摄像头模块对控制一个二维MEMS阵列。通过基于单个摄像头图像处理实现的镜面控制方案，相较于传统方法（需为每个镜面配备独立监测器和/或光电探测器硬件），控制体系得到显著简化。该设计选择对实现低成本、可量产的OCS解决方案至关重要。上述设计可构建非阻塞式136×136 OCS系统，实现输入端口与输出端口之间的双射映射及任意端口互连。

图20展示了帕洛马光纤交叉连接器（OCS）的部分代表性插入损耗与回波损耗数据。所有N×N连接排列的插入损耗通常均小于2dB。分布曲线中的尾部偏差主要源于熔接点与连接器损耗的波动。回波损耗典型值为-46dB，标称规格要求≥-38dB。如此严格的回波损耗要求源于每条光路均采用双向通信——任何单次反射都会直接叠加在主光信号上，从而降低信噪比。基于多级PAM的通信进一步加剧了对这些反射的敏感性。

%0.2 WDM光收发器

图21展示了谷歌过去十年间开发的WDM单模互连路线图[23]。为支持因光交叉系统（OCS）和




图20：a) 136×136（18,496）交叉连接的帕洛马光交叉点典型插入损耗直方图。b) 136个输入/输出端口在光交叉点配置为1:1连接（输入1-输出1，输入2-输出2，...）时的回波损耗与端口号关系图。

在设计收发器时，重点在于降低光学部件和封装损耗。此后，多种技术方向和趋势值得关注。首先，为支持不同代聚合模块间的直接互操作，保持统一的CWDM4波长网格至关重要。这要求在25G每光通道时代就提前开发关键组件技术，其中最核心的是非制冷CWDM直接调制激光器（DML）。该需求最终促成了CWDM4多源协议（MSA）的后续制定。

其次，为持续降低每Gb/s的成本、功耗和密度，并使交换机ASIC/摩尔定律的改进得以应用[23]，必须不断提升每条通道的速度。这一目标通过开发多种关键技术实现：光技术、电技术和信号处理技术。在光学领域，我们与业界合作开发了更高速的光学元件（激光器/光探测器），从直接调制激光器（DML）逐步过渡到外部调制激光器（EML），这是由于更高速度和消光比的要求（这对缓解双向通信中加剧的多路径干扰（MPI）效应至关重要）。




图21：波分复用单模互连技术回顾与发展路线图。

针对高速集成电路/电气技术，我们已从基于模拟技术的时钟数据恢复（CDR）方案转向基于数字信号处理（DSP）的专用集成电路（ASIC）。DSP ASIC通过降低对光电元件的要求提供了更稳健、可扩展的解决方案，但代价是功耗和延迟增加。此外，我们利用新获得的数字能力开发了缓解双向链路固有MPI损伤的算法，以及前向纠错（FEC）技术[42]，以支持基于OCS链路所需的更高链路预算。

互连开发中另一关键要素是光收发器技术的向后兼容性要求。除波长网格兼容性外，这意味着光性能规格与高速数据路径需支持多种线路速率。当前代收发器还必须支持涵盖所有前代收发器收发动态范围的超集。

0.3 光环形器

如前所述，光环形器使DCNI链路能够双向运行，从而将所需的光交叉开关端口和光纤数量减半。光环形器是一种三端口非互易器件，具有循环连接特性。输入端口1的光信号导向端口2，输入端口2的光信号导向端口3。该功能可通过双折射晶体、磁光法拉第旋转器（通常由石榴石制成）及偏振器实现。图22展示了具体实现方案。尽管沿光纤和光环路器传输的反向光信号会相互叠加，但由于光子的玻色子特性，它们不会直接相互作用。与光环路器类似，该环形器的宽带特性使其能够在多代基于CWDM4的光收发器技术中重复使用，相关成本得以相应摊销。




图22：集成环形器实现示例。蓝色线表示s偏振，红色线表示p偏振。PBS - 偏振分束器，FR - 法拉第旋转器，HWP - 半波片。